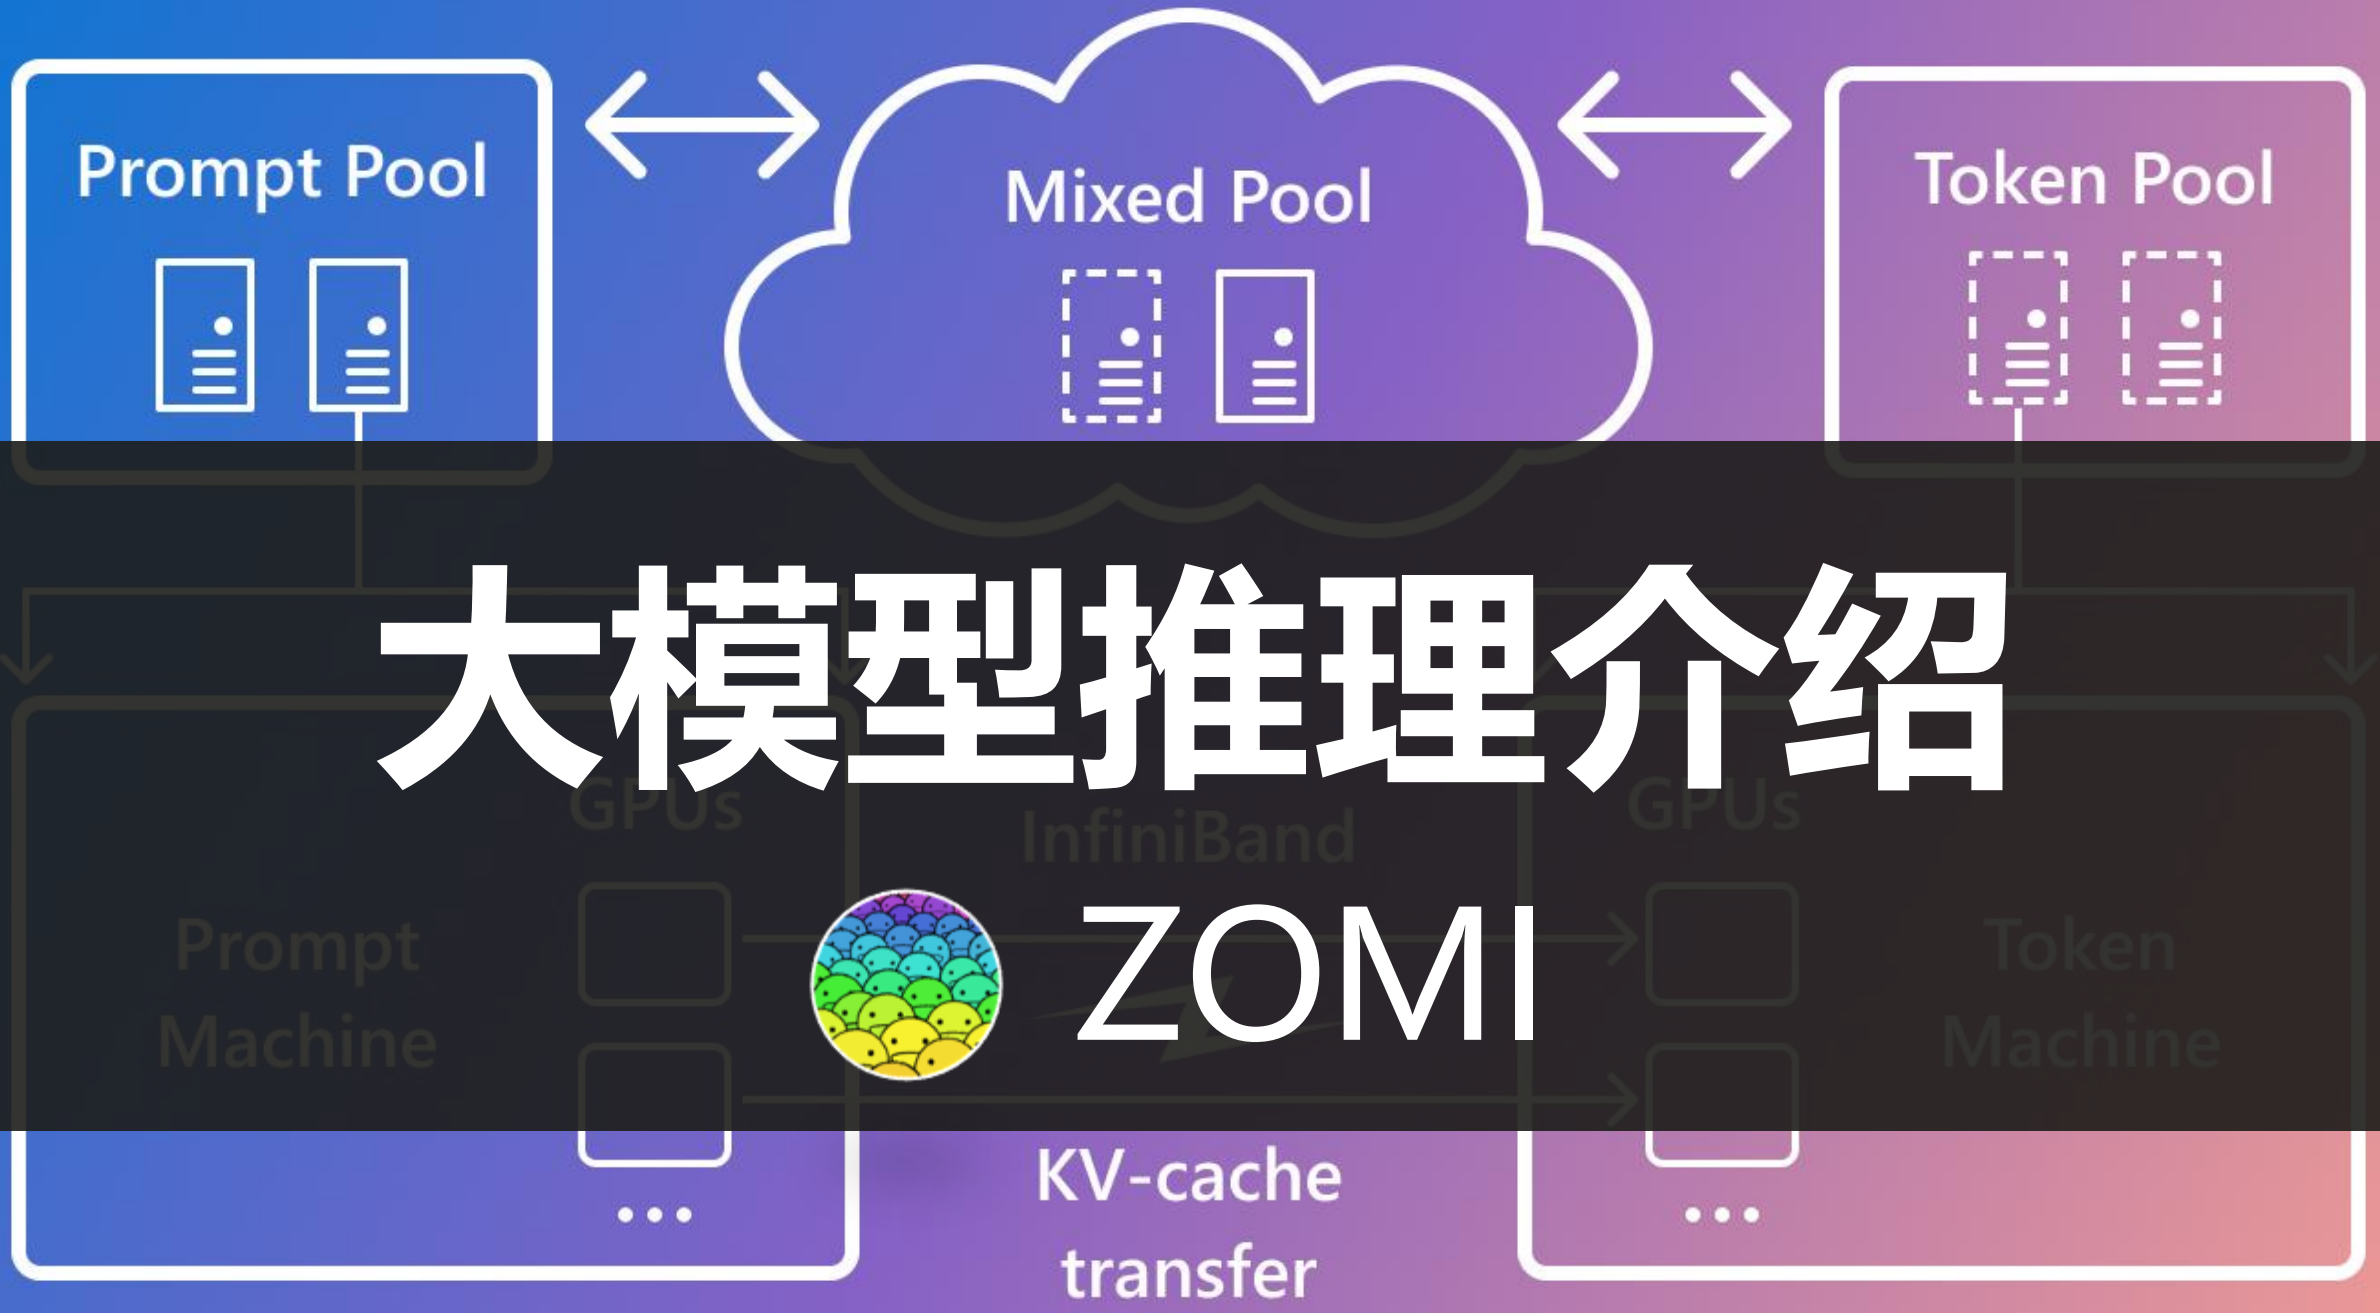

大模型推理介绍

ZOMI

思考

- **大模型推理框架跟传统推理框架，有什么不同?**
  - 大模型推理框架只推理大模型，聚焦 Transformer 架构
  - 大模型推理要包含服务化，主要在云端使用
  - ??? 还有吗？那么架构上有什么区别?

目录

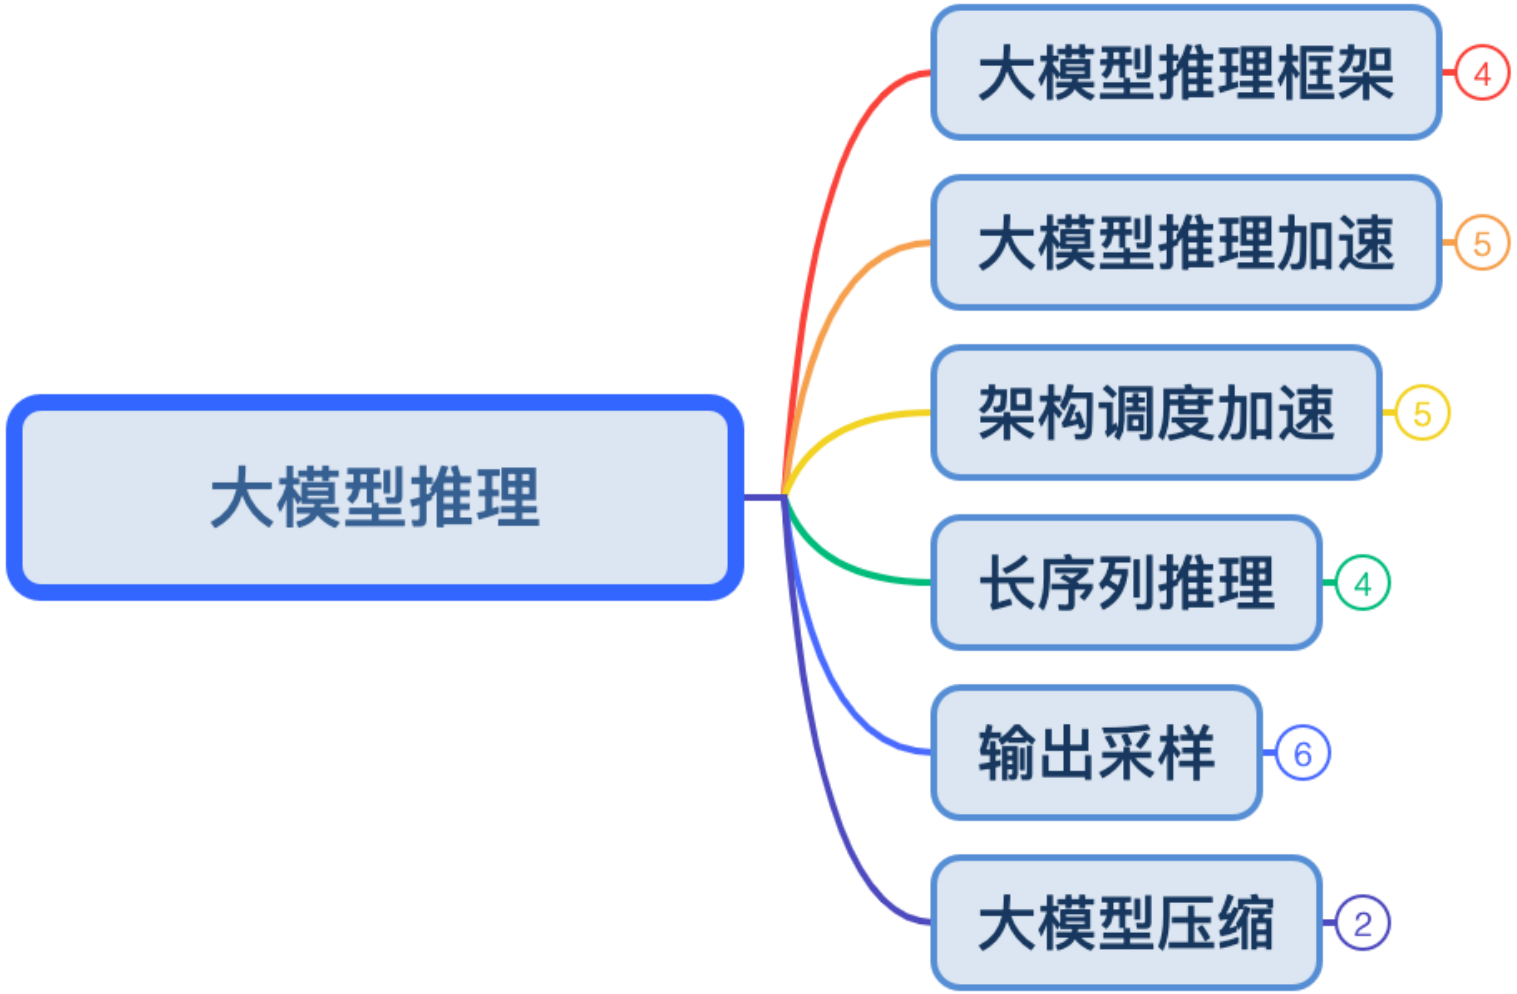
大模型推理
大模型推理框架
4
大模型推理加速
5
架构调度加速
5
长序列推理
4
输出采样
6
大模型压缩
2

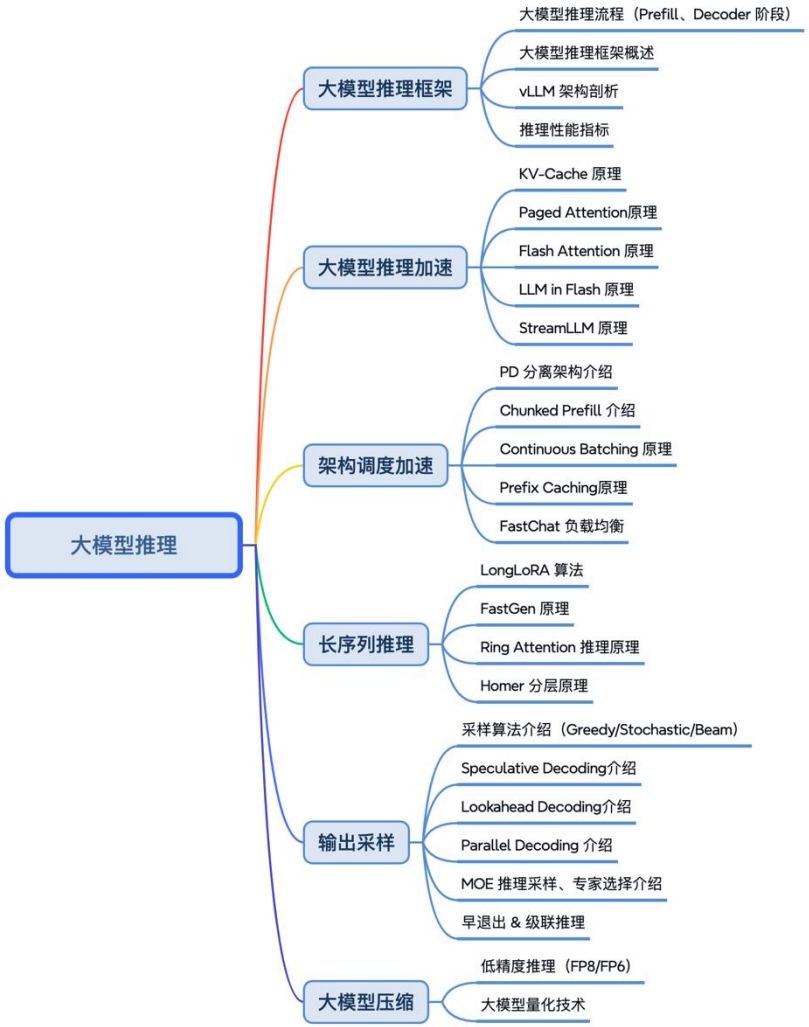
大模型推理
大模型推理框架
大模型推理流程（Prefill、Decoder 阶段）
大模型推理框架概述
vLLM 架构剖析
推理性能指标
大模型推理加速
KV-Cache 原理
Paged Attention原理
Flash Attention 原理
LLM in Flash 原理
StreamLLM 原理
架构调度加速
PD 分离架构介绍
Chunked Prefill 介绍
Continuous Batching 原理
Prefix Caching原理
FastChat 负载均衡
长序列推理
LongLoRA 算法
FastGen 原理
Ring Attention 推理原理
Homer 分层原理
输出采样
采样算法介绍（Greedy/Stochastic/Beam）
Speculative Decoding介绍
Lookahead Decoding介绍
Parallel Decoding 介绍
MOE 推理采样、专家选择介绍
早退出 & 级联推理
大模型压缩
低精度推理（FP8/FP6）
大模型量化技术

大模型推理

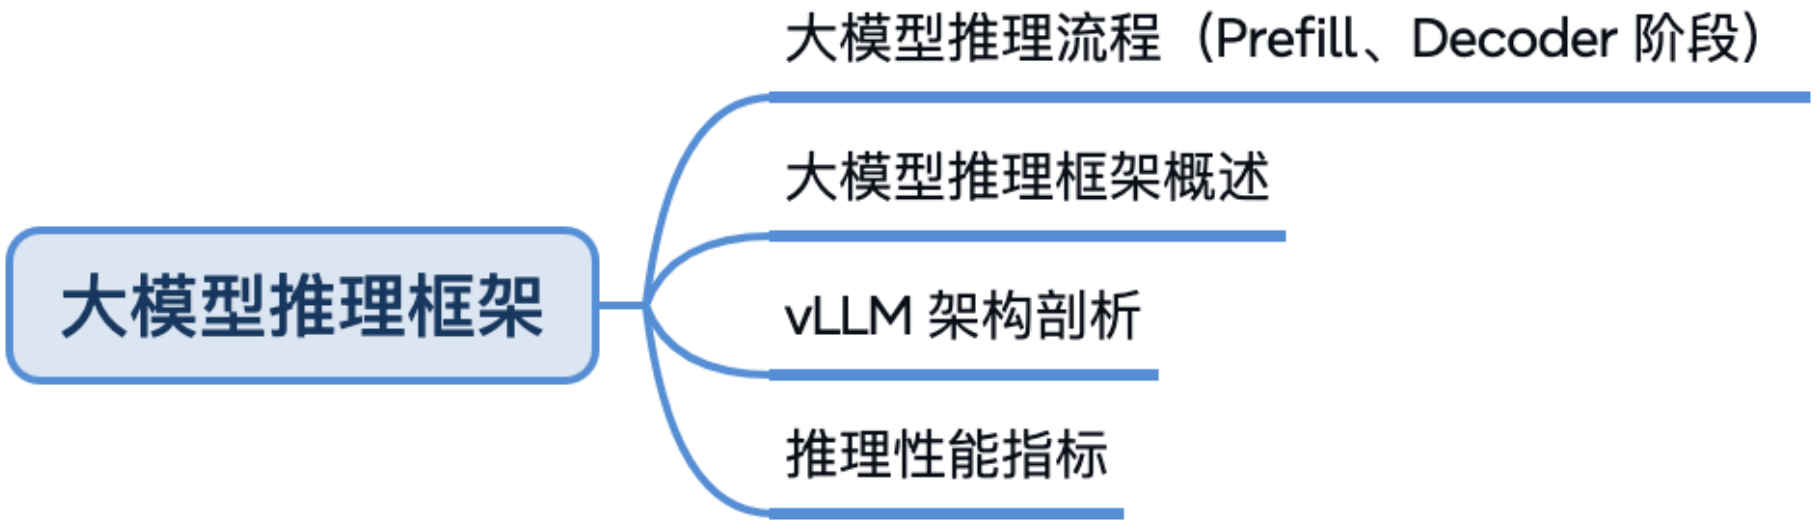
大模型推理框架
大模型推理流程（Prefill、Decoder 阶段）
大模型推理框架概述
vLLM 架构剖析
推理性能指标

大模型推理

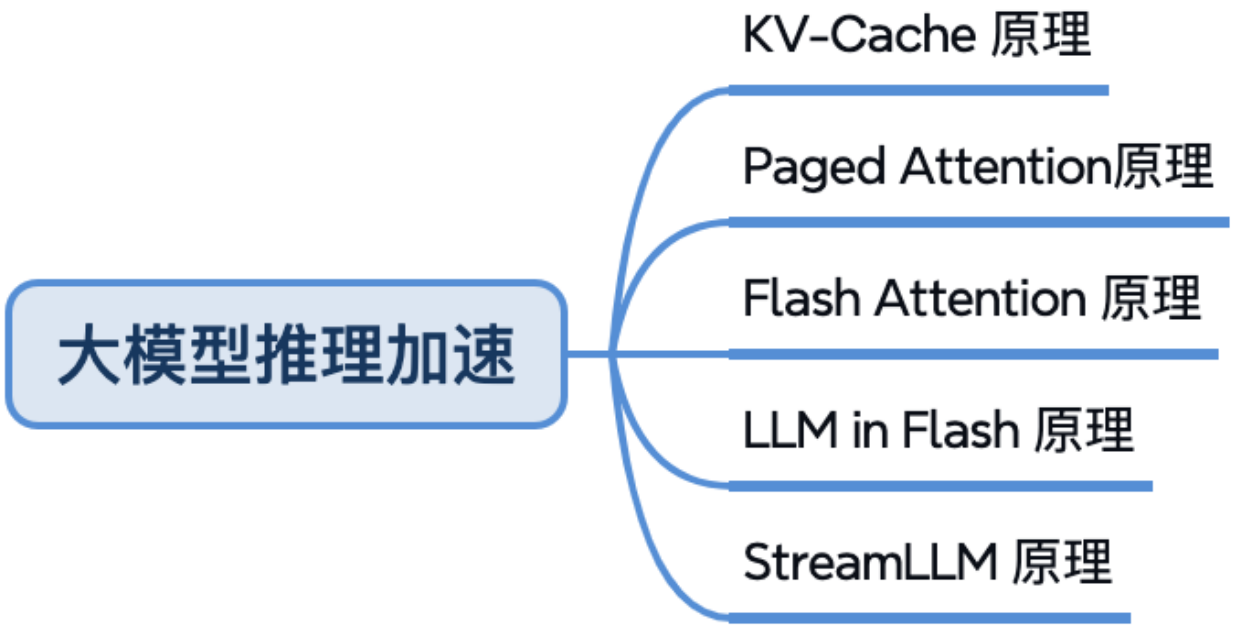
大模型推理加速
KV-Cache 原理
Paged Attention原理
Flash Attention 原理
LLM in Flash 原理
StreamLLM 原理

大模型推理

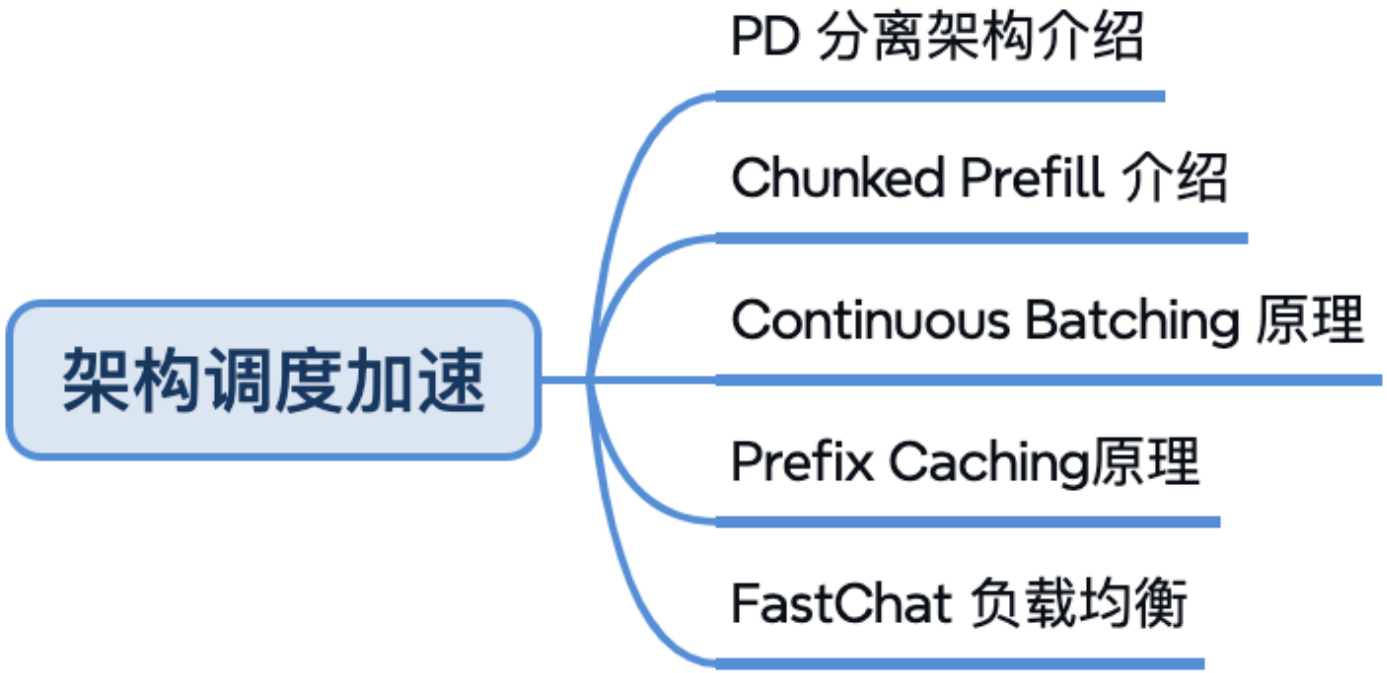
架构调度加速
PD 分离架构介绍
Chunked Prefill 介绍
Continuous Batching 原理
Prefix Caching原理
FastChat 负载均衡

大模型推理

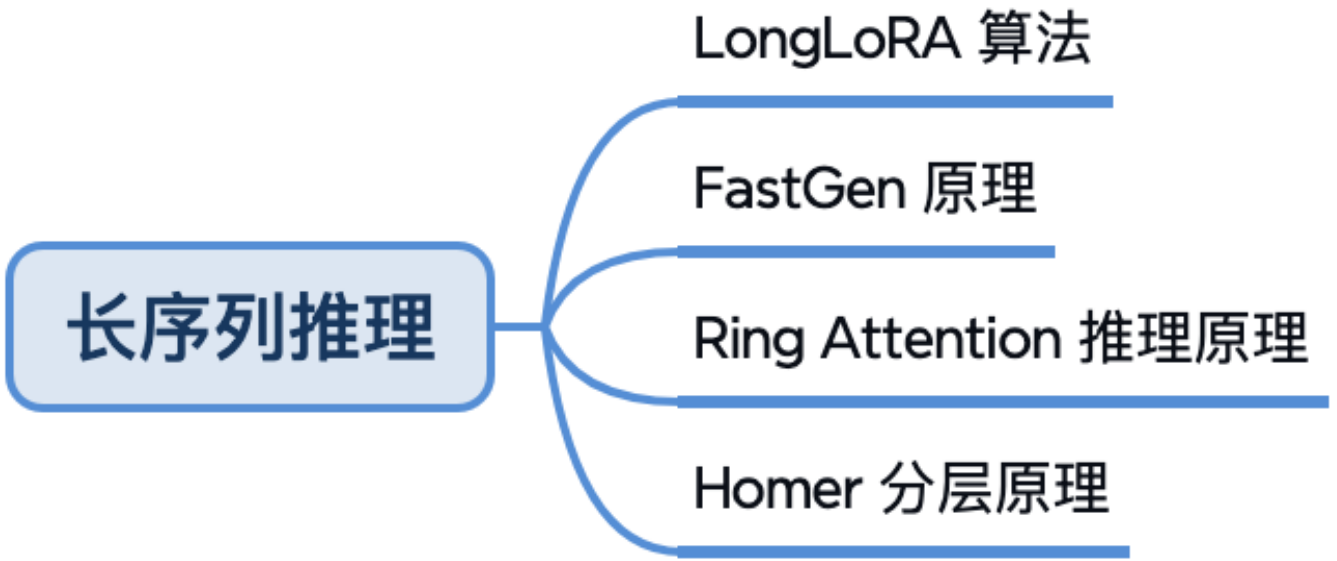
长序列推理
LongLoRA 算法
FastGen 原理
Ring Attention 推理原理
Homer 分层原理

大模型推理

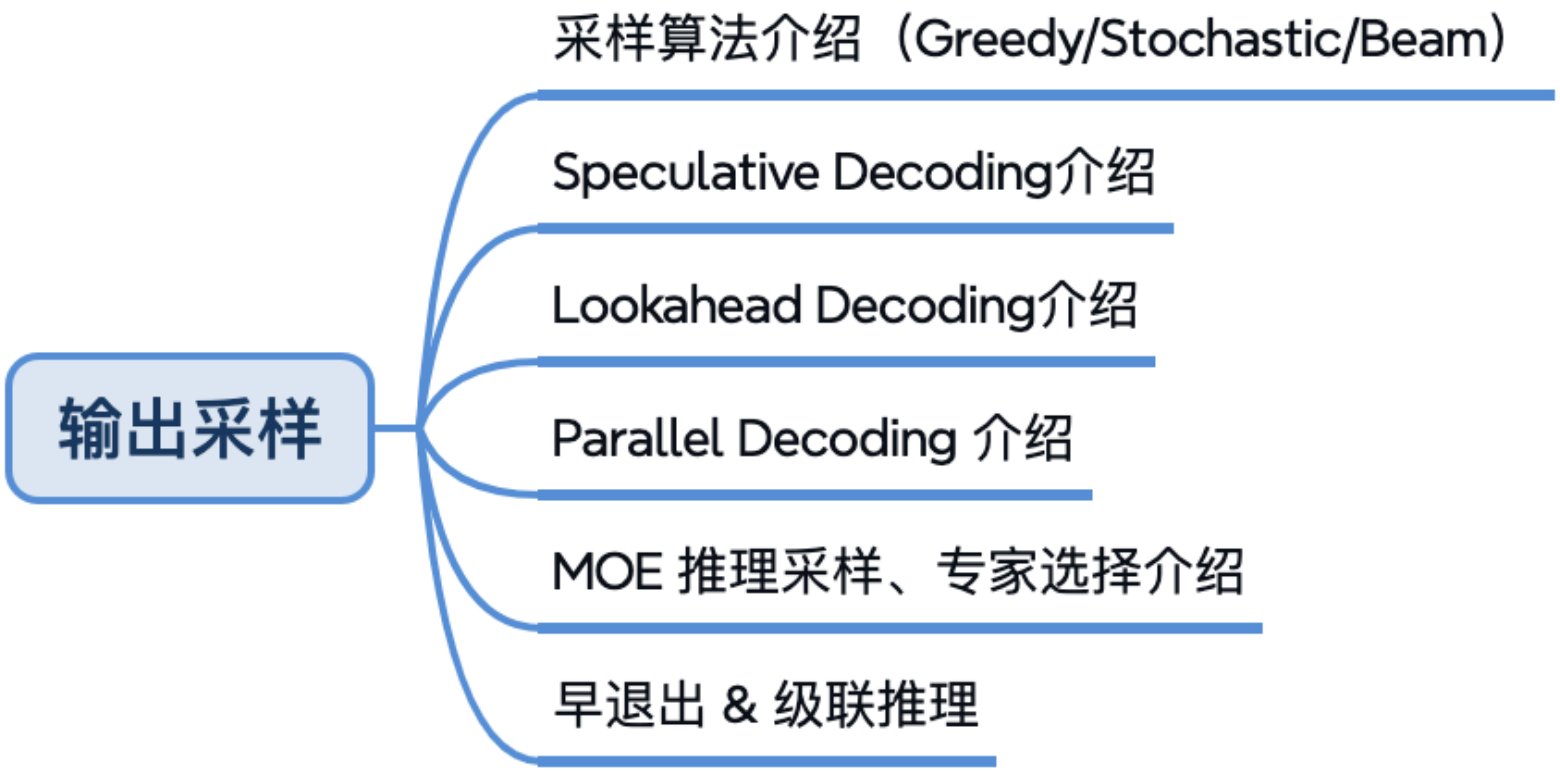
输出采样
采样算法介绍（Greedy/Stochastic/Beam）
Speculative Decoding介绍
Lookahead Decoding介绍
Parallel Decoding 介绍
MOE 推理采样、专家选择介绍
早退出 & 级联推理

大模型推理

Thank you

把AI系统带入每个开发者、每个家庭、每个组织，构建万物互联的智能世界

Bring AI System to every person, home and organization for a fully connected, intelligent world.

ZOMI

GitHub https://github.com/chenzomi12/AIFoundation